

Como base fundamental de este trabajo, a continuación y de forma preliminar,¹ se presenta una visión general modelo; mientras que el resto del capítulo se enfocará en profundizar en cada parta de este. Se trata de seguir la notación usada en los libros de **hastie2008elements** y **james2013introduction**, asimismo al comienzo de este trabajo se presenta un glosario de los símbolos y signos usados.

Se supone la siguiente estructura: $\{(y_i, \mathbf{x}_i)\}_{i=1}^n$ es el conjunto de datos observados independientes con n el tamaño de la muestra donde, $y_i \in \{0, 1\}$ son las variables de respuesta binarias, $\mathbf{x}_i \in \mathcal{X}^d \subseteq \mathbb{R}^d$ las covariables o regresores² y $d \in \mathbb{N}$ la dimensionalidad de las covariables.³ Estos datos se organizan y se representan en una tabla (o matriz) como la presentada en la Tabla 1. En ella, cada fila $i = 1, \dots, n$ representa una observación, la primer columna es el vector de respuestas y las columnas subsecuentes $j = 1, \dots, d$ representan una covariable. Es útil pensar en estas columnas como *d variables o dimensiones* que contienen información que induce la clasificación binaria. Asimismo, se define el espacio de covariables \mathcal{X}^d como el pro-

$$\left[\begin{array}{c|c} y_1 & \mathbf{x}_1 \\ \vdots & \vdots \\ y_n & \mathbf{x}_n \end{array} \right] = \left[\begin{array}{c|ccc} y_1 & x_{1,1} & \dots & x_{1,d} \\ \vdots & \vdots & & \vdots \\ y_n & x_{n,1} & \dots & x_{n,d} \end{array} \right]$$

Tabla 1: Estructura de los datos

ducto cartesiano de los rangos de cada covariable j . Esta definición, está relacionada

1. La versión completa del modelo se presenta en la sección ?? de la página ??
2. Se utiliza la convención de usar negritas para distinguir vectores $\mathbf{x}_i = (x_{i,1}, \dots, x_{i,n}) \quad \forall i = 1, \dots, n$
3. En el lenguaje de aprendizaje de máquina, es usual hablar de *outputs* e *inputs* para referirse a y_i y \mathbf{x}_i respectivamente (**alpaydin2014introduction**).

con los polinomios por partes f_j que se estudian en la Sección: 0.3.

$$\begin{aligned}\mathcal{X}^d &= \mathcal{X}_1 \times \mathcal{X}_2 \times \dots \times \mathcal{X}_d \\ &= [a_1, b_1] \times [a_2, b_2] \times \dots \times [a_d, b_d] \subseteq \mathbb{R}^d \\ \text{con } a_j &= \min \{x_{1,j}, \dots, x_{n,j}\} \quad \forall j = 1, \dots, d \\ b_j &= \max \{x_{1,j}, \dots, x_{n,j}\} \quad \forall j = 1, \dots, d.\end{aligned}$$

Definición 0.1. El modelo probit bayesiano no lineal (preliminar), $\forall i = 1, \dots, n$:

$$y_i = \begin{cases} 1 & \iff z_i > 0 \\ 0 & \iff z_i \leq 0 \end{cases} \quad (1)$$

$$z_i | \mathbf{x}_i \sim N(z_i | \eta(\mathbf{x}_i), 1) \quad (2)$$

$$\eta(\mathbf{x}_i) = f_0 + f_1(x_{i,1}) + f_2(x_{i,2}) + \dots + f_d(x_{i,d}) \quad (3)$$

$$f_j(x_{i,j}) = \sum_{l=1}^{N^*} \beta_{j,l} \Psi_l(x_{i,j}, \mathcal{P}_j) \quad \forall j = 1, \dots, d \quad (4)$$

Las expresiones (1) y (2) introducen n variables latentes z_i independientes entre si con distribución normal. Estas variables se relacionan de forma unívoca con las respuestas y_i formando una clase de equivalencia entre la probabilidad de dos eventos. Permitiendo que se asocie el soporte binario de y_i con el soporte real de z_i . Es decir, (1) y (2) implican:

$$P(y_i = 1 | \mathbf{x}_i) = P(z_i > 0 | \mathbf{x}_i) = \Phi(\eta(\mathbf{x}_i)). \quad (5)$$

Esta definición, **albert1993bayesian**, es equivalente a la definición de un modelo probit pues la función liga resulta en la función de acumulación normal estándar $\Phi : \mathbb{R} \rightarrow (0, 1)$ (Sección 0.1). La identidad anterior (5) es inducida por la demostración de equivalencia entre definiciones que se detalla en el Teorema 0.3. Una de las razones para adoptar este enfoque es que **albert1993bayesian** desarrollaron un método numérico vía simulación, bajo el paradigma bayesiano, para el cómputo exacto de

las distribuciones posteriores de los parámetros $\beta_{j,l}$ el cual resultaba atractivo para los objetivos del trabajo.

Posteriormente, la ecuación (3) especifica la media de las variables latentes z_i , es decir, se le da forma funcional a $\mathbb{E}[z_i|\mathbf{x}_i] = \eta(\mathbf{x}_i)$. A esta función $\eta(\cdot) : \mathbb{R}^d \rightarrow \mathbb{R}$ se le conoce como función de predicción. La idea es suponer que la relación entre los componentes de las covariables $j = 1, \dots, d$, es modelable como la suma de funciones (usualmente suaves) f_j más un término independiente f_0 . Esta definición corresponde a los Modelos aditivos generalizados (GAM) introducidos en **hastie1986generalized**; en la Sección 0.2 se estudia el detalle de este tipo de modelos.

Finalmente, la expresión (4) define a las funciones $f_j \quad \forall j$ en la parte más profunda del modelo. Estas funciones, $f_j : \mathcal{X}_j = [a_j, b_j] \rightarrow \mathbb{R}$ realizan una transformación no lineal de las covariables $x_{i,j}$. Este proceso se lleva a cabo mediante una expansión en bases funcionales revisada a detalle en la Sección 0.3. El objetivo de esta expansión es expresar cada f_j de una forma flexible, a través de la suma ponderada de funciones bases $\Psi_{j,l}(x_{i,j}, \mathcal{P}_j)$ y parámetros desconocidos $\beta_{j,l}$ los cuales se deben de estimar. Asimismo, las funciones bases dependen de tres componentes: las covariables $x_{i,j}$, una partición \mathcal{P}_j para cada dimensión⁴ y el número total de funciones base $N^* \in \mathbb{N}$. Sus formas funcionales, no son más que truncamientos de orden mayor en las covariables, por ejemplo: $(x_{i,j} - a)_+^b$ con a, b constantes definidas por N^* y $(\cdot)_+$ la función parte positiva; dando lugar a una expansión en polinomios por partes, particularmente, la

4. Definida sobre el intervalo $\mathcal{X}_j = [a_j, b_j] \quad \forall j = 1, \dots, d$

presentada en **mallik1998automatic**. Por el momento, se deja a las funciones bases $\Psi_{j,l}$ no especificadas por completo pues se decide presentarlas de forma constructiva en la Sección 0.3.2, derivando en su forma funcional final en las ecuaciones (17) y (18).

Antes de continuar y para esclarecer el trabajo un poco más, en la Figura 1 se presenta un diagrama del modelo y sus componentes. De izquierda a derecha y para toda $i = 1, \dots, n$: se busca transformar de forma no lineal a cada una de las covariables observadas $x_{i,j} \quad \forall j = 1, \dots, d$ a través polinomios por partes condensados en las funciones f_j . Estas transformaciones dependen de parámetros desconocidos $\beta_{j,l}$ con $l = 1, \dots, N^*$ y la partición de cada covariable P_j . Una vez se tienen las covariables transformados, se suman las funciones f_j con un intercepto local f_0 para obtener una función de predicción η . Esta función actúa como la media de la variable latente z_i , que a su vez, conecta a la respuesta y_i con la información adicional contenida en las covariables \mathbf{x}_i , a través de un modelo probit para lograr la clasificación binaria en y_i . Las aparentemente complejas interacciones entre todos los componentes del modelo no son más que respuestas estructurales a un proceso de *síntesis* de la información. El modelo está buscando un patrón en las covariables \mathbf{x}_i para la correcta clasificación de su respuesta binaria asociada y_i . Este proceso, se lleva a cabo mediante tres transformaciones $f_j(x_{i,j}) \quad \forall j$, $\eta(\mathbf{x}_i)$ y finalmente $\Phi(\eta(\mathbf{x}_i))$ las cuales cumplen el propósito de ir colapsando dimensiones. Se espera que este proceso, logre separar de forma flexible el espacio d -dimensional \mathcal{X}^d a regiones más identificables (para la clasificación) que las regiones originales; donde finalmente, se le asigne una probabilidad a cada región de clasificación mediante Φ . El Capítulo ?? cuenta con

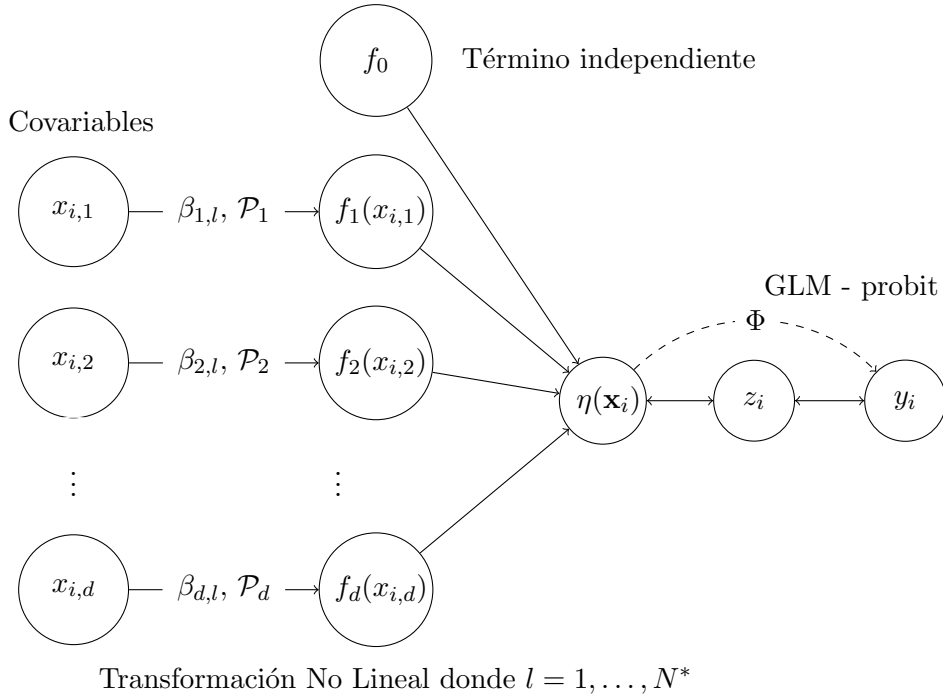


Figura 1: Diagrama del modelo

visualizaciones que esperan volver estos conceptos teóricos en algo más concreto.

Antes de continuar, vale la pena mencionar el precepto de **box1979robustnessinthe**:

All models are wrong but some are useful

En la perspectiva del autor, no se está tratando de construir un modelo que replique el proceso generador de los datos. Más bien, se está tratando de construir una útil abstracción de la realidad a través de un modelo matemático. Escoger cualquier

enfoque de modelado, es un proceso reduccionista y por ende, falible. Sin embargo, no significa que no se puedan discernir patrones en los datos y aprender de ellos.

0.1. Modelos lineales generalizados (GLM)

Los modelos lineales generalizados (GLM), **maccullagh1989generalized**, surgen como una generalización del modelo de regresión lineal:

$$y_i|x_i \sim N(\mu(\mathbf{x}_i), \sigma^2) \quad \forall i = 1, \dots, n$$

$$\mu(\mathbf{x}_i) = \beta_0 + \beta^t \mathbf{x}_i,$$

donde $y_i \in \mathbb{R}$, $\beta \in \mathbb{R}^d$ es un vector de parámetros y $\mu(\mathbf{x}_i) = \mathbb{E}[y_i|x_i]$. Las regresiones lineales, como su nombre lo indica, están acotadas a datos donde la variable de respuesta y_i tenga soporte real. En consecuencia se desarrollan los GLM, que busca flexibilizar este soporte a una mayor cantidad de respuestas. Esta modificación vuelve al modelo más complejo y deriva en diversas técnicas para la estimación de β . Asimismo, la generalización del modelo lleva a que la interpretación de los parámetros no sea trivial.⁵

5. Por ejemplo, en un modelo logit que busca la predicción de variables binarias, se logra expresar el logaritmo de la proporción de probabilidades (*Log-Odds-Ratio*) como una combinación lineal de las covariables. $\ln(\pi_1/\pi_0) = \beta^t x$, donde π_k con $k = \{0, 1\}$, es la probabilidad de que la respuesta y sea 0 o 1 respectivamente.

Definición 0.2. El modelo lineal generalizado, **sundberg2016exponential**:

$$\begin{aligned} y &\sim F(\mu(\mathbf{x})) \\ \eta &= \beta_0 + \boldsymbol{\beta}^t \mathbf{x} \\ \mu &= g^{-1}(\eta) \end{aligned} \tag{6}$$

que cuenta con los siguientes tres elementos:

F : distribución de la familia exponencial que describe el dominio de las respuestas y , cuya media $\mu(\cdot)$ es dependiente de las covariables.⁶ Por ejemplo: Bernoulli si y es binaria, Poisson si $y \in \mathbb{Z}^+$ o una distribución Gamma si $y \in \mathbb{R}^+$

η : predictor lineal que explique (linealmente) la variabilidad sistemática de los datos.⁷

g : función liga que une la media μ de la distribución con el predictor lineal,⁸ es decir: $\mu(x) = \mathbb{E}[y|x] = g^{-1}(\boldsymbol{\beta}^t x)$. g puede ser cualquier función monótona que idealmente mapee de forma suave y biyectiva el dominio de la media μ con el rango del predictor lineal η (**hardle2004semiparametric**).

6. Al trabajar con distribuciones de la familia exponencial es usual parametrizar la distribución no con la media μ sino con el parámetro canónico θ .

7. Como restricción adicional, en el modelo clásico se pide que $\dim(\boldsymbol{\beta}) = d < n$.

8. Si la función g es tal que $\eta \equiv \theta$ entonces se dice que g es la función liga canónica.

0.1.1. El modelo probit

Dado que para este trabajo se busca construir un clasificador supervisado donde las respuestas observadas sean binarias, i.e. $y_i \in \{0, 1\} \forall i = 1, \dots, n$; la discusión se centrará en la distribución Bernoulli pues resulta de forma natural. Esto es:

$$y_i \sim \text{Be}(y_i | p_i). \quad (7)$$

La distribución Bernoulli (7) tiene una estructura sencilla que puede ser resumida en las siguientes expresiones $\forall i = 1, \dots, n$:

$$f(y_i | p_i) = p_i^{y_i} (1 - p_i)^{1-y_i} \quad (8)$$

donde $y_i \in \{0, 1\}$

$$\mathbb{E}[y_i] = \mu_i = P(y_i = 1) = p_i$$

$$\mathbb{V}[y_i] = p_i(1 - p_i).$$

En (8) se observa la función de masa de probabilidad Bernoulli en su forma tradicional que puede ser reexpresada para que cumpla la definición de la familia exponencial.⁹ Dado el soporte y la definición de la distribución Bernoulli, la media de la distribución $\mu = p$ coincide con la probabilidad de que la variable aleatoria tome el valor de uno. Asimismo, la varianza queda especificada por el mismo parámetro p .

9. Una distribución (de un solo parámetro) se dice que pertenece a la familia exponencial si se puede expresar de la forma: $f(y; \theta) = h(y) \exp \{y \cdot \theta - A(\theta)\}$ con $h(y)$, $A(\theta)$ funciones conocidas y θ el parámetro canónico, en el caso Bernoulli: $\theta(p) = \ln p/(1 - p)$.

El que la media conocida con la probabilidad de éxito en una distribución Bernoulli es de gran utilidad en un contexto de regresión. Primero, al modelar la media $\mu = p$, se está caracterizando por completo la distribución y la predicción de la variable y . Segundo, se restringen las posibles funciones liga a las funciones que mapean de forma biyectiva \mathbb{R} , el dominio del predictor lineal η , al intervalo $(0, 1)$, el dominio de la media. Dadas las propiedades buscadas, es usual usar como función liga a las inversas de funciones *sigmoidales*. Las funciones sigmoideas, son funciones $s : \mathbb{R} \rightarrow (0, 1)$ estrictamente monótonas y por ende, biyectivas. Algunos ejemplos son la ya mencionada logit, la función probit que concierne a este trabajo o la curva de Gompertz. Estas funciones cumplen un papel de activación, es decir, una vez que el predictor lineal rebase cierto umbral, crecen rápidamente y toman valores más cercanos a uno, *activando* así la probabilidad de que y sea éxito.¹⁰

En particular, en este trabajo se escoge como función liga a la función probit, la inversa de la función de acumulación normal estándar $\Phi(\cdot)$, i.e. $g(\mu) = g(p) = \text{probit}(p) = \Phi^{-1}(p)$, dándole nombre al modelo, en consecuencia al trabajo de **albert1993bayesian**. Dado que la notación puede ser confusa, en la Figura 2 se presenta una representación gráfica de la función liga para un modelo probit.¹¹

Juntando todos los componentes, se está en posibilidades de detallar el modelo probit en su forma más rigurosa, rescatando la notación de un GLM (6) con sus respectivas

10. En un contexto de aprendizaje de máquina, se les conoce como funciones de activación a las inversas de la función liga g^{-1} (**bishop2006pattern**). Recientemente se utiliza mucho la función $ReLU(x) := \max\{0, x\}$ la cual no es suave ni biyectiva (**3blue1brown2017**).

11. Para no caer en redundancia de notación se tiene a partir de ahora: $s(x) = g^{-1}(x) = \Phi(x)$ la función de acumulación normal estándar. Asimismo, se deja de usar μ para referirse a la media y se utiliza únicamente p




Figura 2: Esquema de función liga g para un modelo probit

covariables \mathbf{x}_i :

$$y_i | \mathbf{x}_i \sim \text{Be}(y_i | p_i) \quad \forall i = 1, \dots, n \quad (9)$$

$$\eta_i = \eta(\mathbf{x}_i) \quad (10)$$

$$p_i = \Phi(\eta_i) = \Phi(f(\mathbf{x}_i)) \quad (11)$$

Equivalencia en las definiciones del modelo

El lector notará, sin embargo, que la especificación del modelo probit en las ecuaciones anteriores no corresponde a la definición mostrada al principio del Capítulo. Sin embargo, a continuación se prueba de forma muy sencilla la equivalencia entre ellas.

Teorema 0.3. *Un modelo probit especificado en (9), (10) y (11), es equivalente a un modelo de variable latente como el presentado en (2) y (1).*

Demostración. Dado un modelo probit se tiene, sin perdida de generalidad $\forall i = 1, \dots, n$:

$$\begin{aligned}\mathbb{E}[y_i | \mathbf{x}_i] &= p_i \\ &= P(y_i = 1 | \mathbf{x}_i) \quad \text{por (9)} \\ &= \Phi(\eta(\mathbf{x}_i)) \quad \text{por (11)}\end{aligned}$$

Lo cual, es equivalente a introducir n variables aleatorias $\tilde{z}_i \sim N(\tilde{z}_i|0, 1)$ tales que:

$$\begin{aligned}\Phi(f(\mathbf{x}_i)) &= P(\tilde{z}_i \leq \eta(\mathbf{x}_i) | \mathbf{x}_i) \text{por definici3n de la funci3n de acumulaci3n} \\ &= P(\tilde{z}_i > -\eta(\mathbf{x}_i) | \mathbf{x}_i) \quad \text{por simetría de la distribuci3n normal} \\ &= P\left(\frac{\tilde{z}_i + \eta(\mathbf{x}_i)}{1} > 0 \middle| \mathbf{x}_i\right) \\ &= P(z_i > 0 | \mathbf{x}_i).\end{aligned}$$

Donde $z_i = \tilde{z}_i + \eta(\mathbf{x}_i)$ es una transformaci3n de \tilde{z}_i tal que:

$$z_i | \mathbf{x}_i \sim N(z_i | \eta(\mathbf{x}_i), 1),$$

lo cual es idéntico a la expresi3n (2). Asimismo, al tener la igualdad $P(y_i = 1 | \mathbf{x}_i) = P(z_i > 0 | \mathbf{x}_i)$ y por ende su probabilidad complementaria $P(y_i = 0 | \mathbf{x}_i) = P(z_i \leq 0 | \mathbf{x}_i)$, se da una correspondencia uno a uno entre espacios de probabilidad y se

puede definir y_i en terminos de z_i y viceversa, dando lugar a la definición (1).

El argumento es similar si la demostración se comienza asumiendo la definición de un modelo de variable latente como en (2) y (1) y se construye hasta llegar a un GLM como en (9) y (11). Sin embargo, se tiene la peculiaridad de que la varianza debe de ser igual a uno para ser que la correspondencia definiciones sea exacta¹² Q.E.D.

La ecuación (10) realmente no influye en la prueba pues esta puede tener la forma funcional que se requiera para la aplicación específica, ya sea lineal $\eta_i = \beta_0 + \beta^t \mathbf{x}_i$ como en (6) o algo diferente como se opta en este trabajo $\eta_i = \eta(\mathbf{x}_i)$.

Liga entre la variable latente z y η

Para entender como se conectan las n variables latentes z_i con sus respectivos predictores lineales $\eta(\mathbf{x}_i)$, se necesita profundizar un poco más en el objetivo del modelo. En la Sección ?? se detalla el algoritmo, derivado del paradigma bayesiano, de las variables latentes z_i y su conexión con los parámetros β .

Recapitulando, mediante la función liga Φ se une la media p_i , la probabilidad de éxito de la respuesta y_i con los datos \mathbf{x}_i . Esto se logra, a través de una variable latente z_i con distribución normal cuya media $\eta(\mathbf{x}_i)$, la función de predicción, es una

12. Comenzar con $z_i|\mathbf{x}_i \sim N(z_i|f(\mathbf{x}_i), \sigma^2)$ con $\sigma^2 \neq 1$ deriva en que $p_i = \Phi(f(\mathbf{x}_i)/\sigma)$ lo cual es diferente a lo que se tiene en (11)

transformación de las covariables \mathbf{x}_i .

$$P(z_i > 0|\mathbf{x}_i) = P(y_i = 1|\mathbf{x}_i) = p_i(\mathbf{x}_i) = \mathbb{E}[y_i|\mathbf{x}_i] = g^{-1}(\eta(\mathbf{x}_i)) = \Phi(\eta(\mathbf{x}_i)) \quad (12)$$

Este enfoque funciona, además de por el componente algorítmico, por la siguiente idea altamente intuitiva. Si se quiere crear una regla de decisión que clasifique observaciones en categorías binarias con base en cierta información, parecería intuitivo condensar esta información de forma que proporcione suficiente evidencia para inducir la clasificación. Es decir y traduciendo en términos matemáticos: la información \mathbf{x}_i se condensa en la función $\eta(\mathbf{x}_i)$ la cual induce la clasificación de y_i a través de la ecuación (12). Por ejemplo, si se tiene una $f(\mathbf{x}_i)$ muy positiva para alguna observación i , implicaría que $P(z_i > 0|\mathbf{x}_i)$ es cercano a uno (por el dominio de Φ y por lo tanto, es muy probable que y_i sea un éxito ($y_i = 1$)). El argumento es idéntico para la probabilidad complementaria.

Al final, como se menciona anteriormente, el modelo está resumiendo información al ir colapsando dimensiones. El siguiente paso en el modelo consiste en detallar la transformación que debe realizar el predictor lineal $\eta(\mathbf{x}_i)$. Tradicionalmente como se mencionó en (6), esta transformación era lineal tanto en parámetros como en covariables, dando lugar a fronteras de decisión lineales. Sin embargo, el siguiente paso lógico es modificar estos modelos para que las fronteras puedan ser más flexibles, rompiendo la linealidad en las covariables para lograr encontrar patrones más complejos.

0.2. La función de predicción η

0.2.1. Una breve introducción a los GAM

Como se detalla en la página 6 de **james2013introduction**, conforme avanzaron los métodos y el poder computacional disponible se fueron desarrollando técnicas cada vez más poderosas que permitieron romper la linealidad en las covariables. En particular, **hastie1990generalized** se agrupan una clase de modelos a los que se les da el nombre de modelos aditivos generalizados (GAM). Estos modelos logran identificar relaciones no lineales utilizando, usualmente, métodos no paramétricos de suavizamiento en los datos adoptando así, un enfoque de *dejar que los datos hablen por si mismos*.¹³

Definición 0.4. Un GAM, tiene la forma $\forall i = 1, \dots, n$:

$$\mathbb{E}[y_i|\mathbf{x}_i] = g^{-1} [f_0 + f_1(x_{i,1}) + \dots + f_d(x_{i,d})], \quad (13)$$

con g^{-1} la inversa de la función liga definida en 0.1 y el predictor lineal $\eta(\mathbf{x}_i) = f_0 + f_1(x_{i,1}) + \dots + f_d(x_{i,d})$.

La idea fundamental de los GAM, es asumir que los efectos en las covariables aún se pueden modelar como una suma de funciones por componentes, es decir, cada covariable $x_j \quad \forall j = 1, \dots, d$ está siendo transformada de forma no lineal e independiente

13. Página 1 de **hastie1990generalized**

por una función asociada $f_j \quad \forall j$. De esta forma, se retiene algo de la interpretabilidad del modelo lineal. Las funciones f_j que ahora componen el predictor lineal η se busca que sean tan flexibles como sea necesario, permitiendo que el estadista pueda hacer menos suposiciones rígidas sobre los datos. Estas funciones f_j son suaves y no especificadas (*no paramétricas*), es decir, no tienen una forma funcional concreta y representable algebraicamente. Sin embargo, es justamente ahí donde recae la fuerza de los GAM: al dejar a las funciones f_j ser no especificadas, se permite que estas capturen los efectos necesarios en los datos para hacer el mejor ajuste posible, a este proceso, se le llama suavizamiento.

Un suavizador, se puede definir de forma general, como una herramienta que resume la tendencia de la respuesta y como función de las covariables \mathbf{x} y produce estimado que es menos variable (ruidoso) que la respuesta en si. Como se mencionó con anterioridad, estos suavizadores son de naturaleza no paramétrica pues no se asume una dependencia rígida de y en \mathbf{x} .¹⁴ Como ejemplos prácticos de métodos no paramétricos, se encuentran los ajustes de medias móviles y el suavizamiento LOESS¹⁵ (**cleveland1988locally**).

La estimación de las funciones f_j , se lleva a cabo por el algoritmo de ajuste hacia atrás (*backfitting algorithm*), **hastie1986generalized**. Este procedimiento, busca dar estimadores de cada f_j de forma iterativa por componentes, utilizando como

14. Las técnicas no paramétricas están fuera del alcance de este trabajo. Sin embargo, vale la pena una mención especial por su funcionalidad, practicalidad y forma intuitiva, además del sinfín de aplicaciones que tienen. Una guía comprensiva de estas se encuentra en el libro **wasserman2007all**.

15. El suavizamiento LOESS, *locally estimated scatterplot smoothing*, es un tipo de regresión local que ajusta modelos más simples a subconjuntos de los datos para construir una función global que describa de forma no lineal la variabilidad intrínseca que se presenta.

regresores los residuales parciales. Por ejemplo, sea $d = 2$ y $g^{-1}(w) = w$ la función identidad, quedando así el modelo:

$$\mathbb{E}[y_i|\mathbf{x}_i] = f_0 + f_1(x_1) + f_2(x_2).$$

Se toman estimadores preliminares \hat{f}_0 y \hat{f}_1 , para suaviza $f_2(x_2)$ sobre los residuales parciales: $\mathbb{E}[y_i|\mathbf{x}_i] - (\hat{f}_0 + \hat{f}_1(x_1))$. Dado entonces \hat{f}_2 se puede mejorar el estimador de $f_1(x_1)$. Ese proceso se lleva a cabo de forma iterativa, hasta que el cambio en las funciones f_j sea menor que un umbral especificado.¹⁶ Este algoritmo, se puede extender para d y g arbitrarias y es bastante flexible a modificaciones. Por construcción, las curvas resultantes de las funciones f_j son suaves y lejos de ser lineales. Asimismo, sus formas, pueden ayudar a entender el fenómeno subyacente, en la página ??, en las figuras ?? se encuentran visualizaciones de las formas finales de f_j ...

Los GAM en el contexto de este trabajo

Sin dudar la elegancia y practicalidad de los métodos no paramétricos, para este trabajo, se opta modificar el enfoque original de los GAM y darles una forma rígida a las funciones f_j , regresando a los dominios de la estadística paramétrica. Esta decisión, pues se busca profundizar en los polinomios por partes estudiados en la Sección 0.3 que componen a las funciones f_j . Aunque pareciera una desviación considerable del trabajo original de **hastie1990generalized**, en realidad en el Apéndice ?? se

16. La demostración de convergencia de un GAM se encuentra en **stone1985additive**

detalla como los polinomios por partes son el resultado de plantear la idea de suavizamiento como un problema de optimización. Asimismo, los GAM son tan flexibles en su definición (y concepto) que es usual restringir las funciones f_j con formas funcionales concretas.¹⁷

Bajo esta óptica, para este trabajo se retienen dos de las ideas fundamentales de los GAM: aditividad y las transformaciones por componentes de las covariables. Es decir, la definición de un GAM (13) sustituye el predictor lineal tradicional de los GLM (6), $\eta(\mathbf{x}_i) = \beta_0 + \beta^t \mathbf{x}_i$, con una suma de funciones $\sum_j^d f_j(x_j)$ más un intercepto constante f_0 que juega el papel de β_0 , dando lugar a la ecuación (3) definida a inicios de este Capítulo:

$$\eta(\mathbf{x}_i) = f_0 + f_1(x_{i,1}) + f_2(x_{i,2}) + \dots + f_d(x_{i,d}). \quad (3)$$

Se hace notar, que a diferencia de los modelos lineales donde se tiene a los parámetros β incluidos en la expansión de η , en los GAM los parámetros se incluyen dentro de cada una de las f_j pues, los efectos de cada covariable son resumidos dentro de las mismas transformaciones. Aunque se pueden agregar parámetros que ponderen cada f_j , sobre-parametrizar puede llevar a la incorrecta especificación del modelo y caer en problemas de identificabilidad de los parámetros.

Al entender que cada f_j es una transformación no-lineal de x_j (como lo sería una transformación logarítmica o una transformación Box-Cox) se le regresa cierta interpretabilidad al modelo. Es decir, cada $f_j(x_{i,j})$ es el efecto que tiene la covariable

17. Capítulo 9.1 y Ejemplo 5.2.2 de **hastie2008elements**

j , para una observación i , en la clasificación. Por lo tanto y heredado de la ecuación (12) si f_j es más positiva para esta observación i , se tiene mayor evidencia (en la covariable j) de que la respuesta binaria asociada y_i sea uno. En la peculiaridad de que $d = 2$, se podrá visualizar, no solo las funciones f_j de manera independiente, sino toda $\eta(\mathbf{x}_i)$ en \mathbb{R}^3 como una serie de picos y valles donde será positiva en caso de que y_i sea clasificada como uno y negativa en caso de que sea cero. La imagen de la página ...

La inclusión de un término independiente f_0 es importante en los GAM pues es uno de los resultados de la derivación mencionada en el Apéndice ??.

Sin embargo, para este trabajo al termino f_0 se le da el mismo tratamiento que el de un parámetro independiente convencional, por lo tanto, se estima usando el mismo procedimiento que todos los demás parámetros. Este hecho se esclarecerá en las secciones subsecuentes.

0.3. Funciones f_j

Finalmente se trata la parte más profunda del modelo, las funciones f_j que, como se mencionó anteriormente, son transformaciones no lineales de cada componente x_j . Lo que buscan es suavizar la nube de datos por componentes, para posteriormente sumarlas entre si y dar una media η que resuma toda la información en un número real. Como se menciona en la introducción de **hardle2004semiparametric**, el suaviza-

miento de los datos es central en la estadística inferencial. La idea es extraer la señal entre el ruido y para ello, se intenta estimar y modelar la estructura subyacente. Este suavizamiento, se llevará a cabo usando una expansión en bases funcionales, particularmente el tipo de polinomios por partes presentados en **mallik1998automatic**. Toda la siguiente Sección se concentra en darle forma funcionales a las sub-funciones Ψ para definir por completo f_j y por ende η .

0.3.1. Expansión en bases funcionales

Saliendo por un momento del dominio de la estadística, se definen las expansiones en bases funcionales. Sin entrar mucho en los detalles técnicos, dado un espacio funcional¹⁸ se puede representar cualquiera de sus elementos, en este caso una función arbitraria h , como la combinación lineal de los elementos de la base Ψ y constantes β . En particular (y dados los objetivos del trabajo) se considera el espacio funcional que mapea \mathbb{R}^d a \mathbb{R} , quedando entonces la expansión:

$$h(\mathbf{x}) = \sum_{l=1}^{N^*} \beta_l \Psi_l(\mathbf{x}) = \beta \beta^t \Psi(\mathbf{x}). \quad (14)$$

Bajo esta definición, $\Psi(\mathbf{x}) = (\Psi_1(\mathbf{x}), \dots, \Psi_{N^*}(\mathbf{x}))^t$ es un vector cuyos elementos $\Psi_l(\mathbf{x})$ son llamados funciones base y tienen el mismo mapeado que h . De la misma forma $\beta = (\beta_1, \dots, \beta_{N^*})^t$ es un vector de coeficientes constantes. Finalmente, $N^* \in \mathbb{N}$

18. Espacio vectorial cuyos elementos son funciones.

es un entero mayor o igual a la dimensión del espacio funcional que se maneja.¹⁹

En un contexto estadístico de regresión, se definen los modelos lineales de bases funcionales,²⁰ Capitulo 3 de **bishop2006pattern**, como:

$$h(\mathbf{x}) = \beta_0 + \sum_{l=1}^{N^*} \beta_l \Psi_l(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^t \boldsymbol{\Psi}(\mathbf{x}), \quad (15)$$

lo cual es idéntico a (14) con la adición del término independiente β_0 .²¹ Bajo este contexto, lo que se busca es representar una transformación g de la media condicional de la respuesta y por una función dependiente de los datos, es decir: $h(\mathbf{x}) = g(\mathbb{E}[y | \mathbf{x}]) = \eta(\mathbf{x})$. Por lo tanto se puede pensar que esta función h , análoga a la función de predicción η , también puede ser expresada como su expansión en bases funcionales.²²

La idea, es que se remplace (o se aumente) la cantidad de covariables \mathbf{x} con transformaciones de estas, capturadas en el vector $\boldsymbol{\Psi}(\mathbf{x})$. Como ejemplos:

$\Psi_l(\mathbf{x}) = x_j \quad \forall l = 1, \dots, N^* = d$, recupera un GLM tradicional.

$\Psi_l(\mathbf{x}) = \ln x_l$ ó $x^{1/2}$ para alguna $l = 1, \dots, N^* = d$, donde se tienen transformaciones no lineales en cada una (o algunas) de las covariables.

19. Dependiendo de el espacio funcional y la complejidad de la función real por estimar h , en ocasiones se requiere que $N^* = \infty$ para que se de la igualdad estricta (**bergstrom1985estimation**).

20. *Linear basis function models*.

21. β_0 es fundamental para el correcto ajuste en el caso que $\mathbf{x}_i = 0$ para alguna i .

22. Un supuesto fuerte pero útil.

$\Psi_l(\mathbf{x}) = \exp \left\{ -\frac{(x_l - \mu_l)^2}{2s^2} \right\} \quad l = 1, \dots, d$ una expansión en bases gaussianas con μ_j el parámetro que gobierna la ubicación y s la escala de las funciones bases.

$\Psi_l(\mathbf{x}) = x_j^a I(\tau_b \leq x_j < \tau_c)$ para alguna j y $\forall l = 1, \dots, N^*$ con $a \in \mathbb{N}$ y τ_b, τ_c nodos fijos. Dando lugar a una expansión en bases polinómicas como la que se usa en este trabajo (Sección 0.3.2).

$\Psi_l(\mathbf{x}) = x_j x_k \quad \forall l = 1, \dots, N^*$, para alguna j, k donde se incluyen términos de interacción.

Como se ve, esta representación engloba muchos de los modelos y transformaciones posibles en el mundo de las regresiones, uniendo temas de análisis funcional con estadística aplicada. Además de que en general han resultado ser de gran utilidad en la práctica. Se hace notar que el último ejemplo rompe con la aditividad inherente de los modelos que se han estudiado hasta ahora, mostrando que esta generalización no está restringida a ser completamente aditiva en covariables. Sin embargo h , por su construcción, siempre es lineal en los parámetros β pero no lineal en las covariables, dependiendo de la forma de $Psi(\mathbf{x})$.

De igual forma, dependiendo del tipo de datos y el propósito del modelo, puede ser conveniente usar algún tipo de funciones base sobre otras. Sin embargo, sobre todo cuando se tiene poca o ninguna experiencia con los datos, se busca una representación más flexible (por no decir la ingenua) de éstos. El método más común es tomar una familia grande de funciones que logre representar una gran variedad de patrones. No

obstante, una desventaja de estos métodos es que al contar con una cantidad muy grande de funciones base y por ende parámetros, se requiere controlar la complejidad del modelo para evitar el *sobre-ajuste*. Algunos de los métodos más comunes para lograrlo son los siguientes (**hastie2008elements**):

Métodos de restricción: donde se selecciona un conjunto finito de funciones base y su tipo, limitando así las posibles expansiones. Los modelos aditivos como los usados en este trabajo, son un ejemplo de esto.

Métodos de selección de variables: como lo son los modelos CART y MARS,²³ donde se explora de forma iterativa las funciones base y se incluyen aquellas que contribuyan a la regresión de forma significativa.

Métodos de regularización: donde se busca controlar la magnitud los coeficientes, buscando que la mayoría de ellos sean cero, como lo son los modelos *Ridge* y *LASSO*.²⁴

Se hace notar que en la Sección anterior, se modelaba η , sin embargo para los objetivos de este trabajo, lo que se busca expresar en su expansión de bases funcionales no es la función de predicción η , sino sus componentes aditivos f_j los cuales depende únicamente de una variable real $x_j \quad \forall j$.²⁵ Por lo tanto, se trabaja por el momento

23. *Classification & regression tree* (**breiman1984classification**) y *multivariate adaptive regression splines* (**friedman1991multivariate**) respectivamente.

24. *Least absolute shrinkage and selection operator* (**hoerl1970ridge; tibshirani1996regression**)

25. Más adelante se verá que la exposición es análoga pero se simplifica mucho el número de índices.

únicamente con funciones que mapeen reales a reales.

0.3.2. Polinomios por partes y *splines*

Los polinomios por partes, por su flexibilidad, ha resultado ser de gran utilidad en diversas ramas de las matemáticas. En particular, el mundo de la estadística surgen de forma natural como solución a varios problemas de modelado (Ver Apéndice ??). Antes de dar la expresión final de las funciones f_j , se da una exposición constructiva de estos. Se usa como referencia las primeras dos secciones de el Capítulo 5 de **hastie2008elements** y **wahba1990splines**.

Sea $x \in [a, b] \subseteq \mathbb{R}$, se busca separar $[a, b]$ en J intervalos. Por lo tanto, se construye una partición correspondiente $\mathcal{P} = \{\tau_1, \tau_2, \dots, \tau_{J-1}\}$ tal que $a \leq \tau_1 < \dots < \tau_{J-1} \leq b$, las constantes τ son llamadas *nodos*.²⁶ Con los nodos seleccionados, se puede hacer una representación de una función arbitraria h en su expansión de bases como en la ecuación (14), donde cada Ψ_j será una función que depende, tanto de la partición \mathcal{P} como de la variable real x .

Un ejemplo sencillo: sea $J = 3$, separando el intervalo en tres pedazos, es decir la partición tiene dos nodos $\mathcal{P} = \{\tau_1, \tau_2\}$. A cada subintervalo se le asocia una función

26. En la definición, se puede incluir o no la frontera dependiendo de si se busca hacer inferencia fuera del intervalo acotado de los datos.

Ψ_j ,

$$\Psi_1(x, \mathcal{P}) = I(x < \tau_1)$$

$$\Psi_2(x, \mathcal{P}) = I(\tau_1 \leq x < \tau_2)$$

$$\Psi_3(x, \mathcal{P}) = I(\tau_2 \leq x),$$

con $I(\cdot)$ la función indicadora que vale uno si x se encuentra en la región y cero en otro caso. De donde se construye una función h :

$$\begin{aligned} h(x) &= \sum_{l=1}^J \beta_l \Psi_l(x) \\ &= \beta_1 I(x < \tau_1) + \beta_2 I(\tau_1 \leq x < \tau_2) + \beta_3 I(\tau_2 \leq x). \end{aligned}$$

Esta función h es una función escalonada, en el sentido de que cada región de x tiene un nivel β_j .²⁷

Con este ejemplo, se ilustra a grandes rasgos como funcionan los polinomios por partes. Sin embargo, los polinomios por partes son mucho más flexibles pues a cada intervalo se puede ajustar un polinomio de grado arbitrario $(M-1)$.²⁸ Adicionalmente, se puede añadir restricciones de continuidad en los nodos, y no sólo continuidad entre los polinomios, sino continuidad en las derivadas. Esta es la flexibilidad de los polinomios por partes, que se les puede pedir cuanta *suavidad* (o no) se requiera,

27. Dado un conjunto de observaciones $\{(y_i, x_i)\}_{i=1}^n$, si se buscara estimar los parámetros β usando una función de pérdida cuadrática, es fácil demostrar que cada $\hat{\beta}_j = \bar{y}_j$ es decir, para cada región, el mejor estimador constante, es el promedio de los puntos de esa región.

28. Se usa esta convención pues para representar un polinomio de grado $M-1$ se necesitan M términos.

entendido como la continuidad de la (\tilde{K}) -ésima derivada.

Número total de funciones bases N^*

Formalizando la idea anterior, al tomar una expansión de bases para cada intervalo, el número de funciones base aumenta en J por cada grado que se agregue, dando un total de $J \times M$ bases funcionales. Esto ocurre porque se necesita definir una base de tamaño M para cada subintervalo $j = 1, \dots, J$, es decir, $\mathcal{B}_j = \{1, x, x^2, \dots, x^{M-1}\}$. Esta definición, lleva a polinomios que se comportan de forma independiente en cada intervalo y no se conectan. Naturalmente, la primera condición en la que se piensa, es imponer continuidad en los nodos lo cual devuelve $J - 1$ parámetros que corresponden a los $J - 1$ nodos. De la misma forma, cada grado de continuidad en las derivadas que se le pida al polinomio, lo restringe y por ende, devuelve el mismo número de funciones bases, se denota por \tilde{K} este número. Sin embargo, es más intuitivo pensar en un parámetro $K = \tilde{K} + 1$ como el número de restricciones que se imponen en los nodos. Es decir, $K = 0$ implica intervalos independientes, $K = 1$, implica que los polinomios se conectan, $K = 2$ implica continuidad en la primera derivada ($\tilde{K} = 1$) y así sucesivamente. Bajo esta definición los polinomios por partes tienen un total de:

$$N^*(M, J, K) = M \times J - K(J - 1) \quad (16)$$

bases funcionales y por ende, el mismo número de parámetros β por estimar. Dada la construcción que se hace y las características de M , J y K se tienen las restricciones:

$M > K \geq 0$ y $J > 1$.

La palabra *spline* usualmente se usa para designar a un grupo particular de polinomios por parte. Sin embargo, no hay consenso en la literatura de su definición exacta. Para este trabajo se usa la definición de **wasserman2007all** y **hastie2008elements**. Un *spline de grado M* es un polinomio por partes de grado $M - 1$ y continuidad hasta la $(M - 2)$ -derivada ($K = M - 1$). Se hace notar, que existen muchos tipos de *splines*, además de que pueden ser más flexibles o más rápidos en su implementación computacional como los B-Splines. En **deboor1978splines** y más recientemente **wahba1990splines** se hacen tratados extensivos sobre ellos y sus generalizaciones. Los *splines* cúbicos se han popularizado en la literatura, pues resultan en curvas suaves al ojo humano, reteniendo suficiente flexibilidad para aproximar una gran cantidad de funciones.

Polinomios por parte flexibles

Habiendo delimitado el número de funciones bases N^* y por ende sus componentes M , J y K , finalmente se le puede dar forma funcional a las funciones base Ψ . Se define primero, la función auxiliar *parte positiva*, sea $a \in \mathbb{R}$:

$$a_+ = \max \{0, a\}.$$

Esta función, ayuda a que se pueda representar un polinomio por partes de una forma relativamente sencilla evitando separar la función en varias líneas.

Definición 0.5. Expansión en bases truncada, **mallik1998automatic**:

$$h(x) = \sum_{l=1}^{N^*} \beta_l \Psi_l(x, \mathcal{P}) = \beta^t \Psi(x, \mathcal{P}) \quad (17)$$

donde, $N^* = J \times M - K(J - 1)$

$$= \underbrace{\sum_{i=0}^{M-1} \beta_{i,0} x^i}_{\text{polinomio base}} + \underbrace{\sum_{i=K}^{M-1} \sum_{j=1}^{J-1} \beta_{i,j} (x - \tau_j)_+^i}_{\text{parte truncada}} \quad (18)$$

Esta expansión aunque pesada en notación, tiene muchas propiedades atractivas. Además, es prácticamente la expansión de bases implementada en el modelo final.

Al primer sumando de (18) se le conoce como polinomio base (*Baseline polynomial*), pues afecta a todo el intervalo de definición $[a, b]$. El segundo sumando, conocido como la parte truncada, controla la suavidad entre los nodos. Es decir, por cada nodo $j = 1, \dots, J - 1$ se tienen $M - K$ funciones parte positivas que se van activando a medida que x recorre el su dominio $[a, b]$ hacia la derecha y va pasando por los nodos τ_j . Estas funciones parte positiva, van capturando los efectos de los intervalos anteriores que, al combinarlos con el primer sumando definen un polinomio de grado $M - 1$ en todo el intervalo.²⁹ La principal utilidad de esta expansión, es que engloba todas las ideas antes mencionadas en tres parámetros: M , J y K , al escogerlos, se pueden representar un gran número polinomios por partes. Por ejemplo, si $M = 3$, $J = 5$, $K = 0$ se tiene un polinomio por partes en 5 subintervalos (4 nodos) donde

29. Esta expansión, surge de integrar un polinomio por partes, constante en cada subintervalo, $M - 1$ veces, pues las constantes de integración se pueden agrupar en el polinomio base.

cada subintervalo es una parábola independiente de la anterior, es decir, las parábolas no son continuas entre si. Por el contrario, si $K = M - 1$ se devuelve a la definición de *splines*.

Para la facilitar la interpretación de los parámetros y la expansión de (18), las β cuentan dos índices: i y j . El índice i siempre está asociado al grado de su función base asociada, es decir, si $i = 2$ se está hablando de un término de grado 2. En el segundo sumando (la parte truncada) el índice i comienza en K para codificar las restricciones de continuidad.³⁰ El segundo índice $j = 1, \dots, J - 1$ describe el nodo al que está asociado el parámetro. Como convención, si $j = 0$, se hace referencia al primer sumando (el polinomio base) que siempre está activo sobre el intervalo.

La ecuación (17) es una expansión en bases arbitrarias igual a (14). Se hace notar, que en (17) se hace referencia a β con un solo índice $l = 1, \dots, N^*$ mientras que en (18) con dos. Esta disparidad surge de la necesidad de una doble interpretación de la expresión; como una expansión de bases arbitrarias Ψ_l y su correspondiente expansión en bases truncadas. Sin embargo, existe una biyección notacional entre los elementos β_l , $\beta_{i,j}$ y Ψ_l presentada en la Tabla 2 de la página 30. Esta Tabla ayuda no sólo a esclarecer la notación, sino a expresar todo de forma matricial que posteriormente se implementará en el código.

30. Esta codificación es sutil pues, al hacer la demostración de continuidad, hay que considerar los límites izquierdos y derechos. Los límites izquierdos siempre coinciden con la función en el nodo. Sin embargo, los términos $(x - \tau)_+^K$ se desvanecen únicamente hasta la (K) -ésima derivada. Para la $(K + 1)$ -derivada, el coeficiente correspondiente se suma a la función y rompe la continuidad pues no corresponde el límite derecho.

β_l	$\beta_{i,j}$	$\Psi_l(x, \mathcal{P})$	
Subíndice l	Subíndices i, j	Función Base	
1	0, 0	1	} M elementos
2	1, 0	x	
\vdots	\vdots	\vdots	
M	$M - 1, 0$	x^{M-1}	
$M + 1$	$K, 1$	$(x - \tau_1)_+^K$	} $M - K$
$M + 2$	$K + 1, 1$	$(x - \tau_1)_+^{K+1}$	
\vdots	\vdots	\vdots	
$M + (M - K)$	$M - 1, 1$	$(x - \tau_2)_+^{M-1}$	
$M + (M - K) + 1$	$K, 2$	$(x - \tau_2)_+^K$	} $M - K$
$M + (M - K) + 2$	$K + 1, 2$	$(x - \tau_2)_+^{K+1}$	
\vdots	\vdots	\vdots	
$M + 2(M - K)$	$M - 1, 2$	$(x - \tau_2)_+^{M-1}$	
\vdots	\vdots	\vdots	} $M - K$
$M + (J - 2)(M - K) + 1$	$K, J - 1$	$(x - \tau_{J-1})_+^K$	
$M + (J - 2)(M - K) + 2$	$K + 1, J - 1$	$(x - \tau_{J-1})_+^{K+1}$	
\vdots	\vdots	\vdots	
$M + (J - 1)(M - K)$	$M - 1, J - 1$	$(x - \tau_{J-1})_+^{K+1}$	} $M - K$

Tabla 2: Biyección entre β_l , $\beta_{i,j}$ y sus correspondientes funciones base Ψ_l .

Se tienen $N^* = M + (J - 1)(M - K) = J \times M - K(J - 1)$ términos, ecuación (16). Por construcción, se es consistente con la definición de *spline* si $K = M - 1$.

Los nodos τ : el trabajo de `mallik1998automatic`

Las ideas de `mallik1998automatic`, van más allá de la ecuación (18). En su trabajo, los autores presentan un método automático y bayesiano para estimar con un alto grado de precisión relaciones funcionales complejas. En el trabajo original, se buscaba ajustar una curva tal que $y = h(x)$. El modelo en su forma estadística se plantea para un conjunto de datos $\{(y_i, x_i)\}_{i=1}^n$:

$$y_i = h(x_i) + e_i \quad i = 1, \dots, n \quad (19)$$

donde las e_i son variables aleatorias con media cero.

Para lograrlo, usan el polinomio definido en (18) y desarrollan un método bayesiano para la estimación de los nodos τ que son tradicionalmente fijos. Además permiten aumentar o disminuir la cantidad de estos nodos desarrollando un algoritmo Gibbs sampler trans-dimensional, es decir, que cambia el número de parámetros en cada iteración. Esta generalización, logra estimaciones tan robustas que logran aproximar funciones continuas *casi en todas partes* como lo son la función Doppler, funciones por bloques y funciones con picos pronunciados. Con lo anterior, se demuestra que la suavidad, aunque útil, no siempre es necesaria. Muchas funciones discontinuas no se podrían estimar del todo usando polinomios continuos como los *splines*. Al final, todo depende de los datos y el propósito del modelo.

La ventaja de que nodos sean parámetros por estimar, es que se estos pueden concentrar en los lugares donde la función varía más. Y al contrario, si la función es

relativamente suave para alguna sección, se necesitan usar pocos nodos. Sin embargo y para propósitos de este trabajo, los nodos se toman determinados desde el principio. Su número $J - 1$ es definido por el estadista y su localización se escoge en los cuantiles del rango de las covariables.³¹ En el Capítulo ?? se detalla como la simplificación de no incorporar los nodos como parámetros ayuda bastante a la velocidad del algoritmo. Posteriormente en el Capítulo ??, se ve que para fines prácticos, el modelo funciona muy bien y finalmente en el Capítulo ?? se discute que habría cambiado de haberse implementado.

0.3.3. Consideraciones finales para el modelo

Bajo la óptica de la implementación del modelo, se hace énfasis en la linealidad de los parámetros. Al sustituir (4) en (3) este hecho se hace más evidente:

$$\begin{aligned}
\eta(\mathbf{x}_i) &= f_0 + \sum_{j=1}^d f_j(x_{i,j}) \\
&= f_0 + \sum_{j=1}^d \beta_j^t \Psi(\mathbf{x}_i, \mathcal{P}_j) \\
&= f_0 + \sum_{j=1}^d \left[\sum_{l=1}^{N^*} \beta_{j,l} \Psi_l(x_{i,j}, \mathcal{P}_j) \right].
\end{aligned} \tag{20}$$

31. Es decir, si se tiene J intervalos, se toman los nodos como los cuantiles que acumulan probabilidad $1/J$ en el rango $[a, b]$.

En donde cada sumando interior tiene una expansión de bases funcionales definida por la ecuación (18).³² Asimismo, f_0 puede ser pensado como otro parámetro adicional, es decir: $f_0 = \beta_0$. Este hecho de linealidad en los parámetros de η , lleva a que (20) pueda ser re-expresada simplemente como el producto punto de un largo vector de parámetros β y una matriz de diseño $\tilde{\Psi}$ que incorpora la doble suma con sus correspondientes expansiones en bases y todas las observaciones $i = 1, \dots, n$. Sin embargo, bajo las definiciones anteriores aún se tiene un problema de confusión en los parámetros.

Al ya tener un término independiente $f_0 = \beta_0$ en el modelo, para preservar la identificabilidad de los parámetros se deben realizar unas pequeñas modificaciones a (18). Los parámetros confundidos pueden tener dos orígenes. Primero, si se permite que $K = 0$ el segundo sumando tendría términos independientes no deseados. Esto se arregla fácilmente imponiendo la restricción de continuidad en los polinomios, es decir, $K > 0$.³³ Segundo, se debe retirar el término independiente inherente en el polinomio base, es decir, comenzar el primer sumando en uno en vez de cero. Esta modificación retira una función base modificando N^* .³⁴ Juntando estas cambios (18)

32. No se hace la sustitución pues la notación resultaría demasiado pesada.

33. De manera preeliminar, se implementó una versión del algoritmo que permitía esta confusión. El ajuste no mejoraba cuando $K = 0$ y solamente causaba que las cadenas simuladas de los parámetros no convergieran debidamente. No obstante, en los polinomios por partes si se observaba la discontinuidad.

34. **mallik1990automatic** resuelven este problema de identificabilidad al solamente usar una covariable para la estimación de las curvas, permitiendo retirar uno de los parámetros independientes sin penalización. Asimismo, su algoritmo automático trans-dimensional les permitía tener polinomios por partes discontinuos.

se transforma en:

$$\begin{aligned}
h(x) &= \sum_{l=1}^{N^*} \beta_l \Psi_l(x, \mathcal{P}) \\
\text{con } N^* &= J \times M - K(J-1) - 1 \\
\text{donde: } M &> K > 0 \text{ y } J > 1 \\
&= \sum_{i=1}^{M-1} \beta_{i,0} x^i + \sum_{i=K}^{M-1} \sum_{j=1}^{J-1} \beta_{i,j} (x - \tau_j)_+^i.
\end{aligned} \tag{21}$$

Lo cual, es finalmente la expansión que se implementa en el modelo. Solamente basta dejar que $h(x)$ sea igual a $f_j(x_j)$ para toda $j = 1, \dots, d$ y se regresa a la ecuación canónica del modelo (4).

Juntando todo lo anterior, el predictor lineal η se puede re-expresar en su forma vectorial compacta:

$$\eta(\mathbf{X}) = \tilde{\Psi}(\mathbf{X})\boldsymbol{\beta}, \tag{22}$$

donde $\mathbf{X} \in \mathbb{R}^{n \times d}$ es la matriz de covariables, $\boldsymbol{\beta}$ el vector de parámetros con un total de $\lambda = 1 + d \times N^*$ elementos y $\tilde{\Psi}(\mathbf{X}) \in \mathbb{R}^{n \times \lambda}$ la transformación no lineal definida con anterioridad. Vistos en sus correspondientes formas matriciales, se tienen las

estructuras:

$$\boldsymbol{\eta}(\mathbf{X}) = \begin{bmatrix} \eta(\mathbf{x}_1) \\ \eta(\mathbf{x}_2) \\ \vdots \\ \eta(\mathbf{x}_n) \end{bmatrix} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{N^*} \\ \beta_{N^*+1} \\ \vdots \\ \beta_{2N^*} \\ \vdots \\ \beta_{d \times N^*} \end{bmatrix} \left. \begin{array}{l} \text{término independiente} \\ \left. \begin{array}{l} \beta_1 : N^* \text{ términos} \\ \beta_2 : N^* \text{ términos} \end{array} \right\} \right\} d \text{ veces}$$

$$\begin{aligned} \tilde{\Psi}(\mathbf{X}) &= \begin{bmatrix} 1 & f_1(x_{1,1}) & \dots & f_d(x_{1,d}) \\ \vdots & \vdots & & \vdots \\ 1 & f_1(x_{n,1}) & \dots & f_d(x_{n,d}) \end{bmatrix} \\ &= \begin{bmatrix} 1 & \Psi_1(x_{1,1}, \mathcal{P}_1) & \dots & \Psi_{N^*}(x_{1,1}, \mathcal{P}_1) & \dots & \Psi_1(x_{1,d}, \mathcal{P}_d) & \dots & \Psi_{N^*}(x_{1,d}, \mathcal{P}_d) \\ \vdots & \vdots & & \vdots & & \vdots & & \vdots \\ 1 & \Psi_1(x_{n,1}, \mathcal{P}_1) & \dots & \Psi_{N^*}(x_{n,1}, \mathcal{P}_1) & \dots & \Psi_1(x_{n,d}, \mathcal{P}_d) & \dots & \Psi_{N^*}(x_{n,d}, \mathcal{P}_d) \end{bmatrix} \end{aligned} \quad (23)$$

Bajo esta definición, el modelo se simplifica. Se observa que en realidad cada f_j es justamente una expansión de cada covariable x_j en más términos que se le añaden al predictor lineal. Asimismo, aunque el modelo no sufra de problemas de identificabilidad en los parámetros, no se puede asegurar la no-colinealidad entre las columnas de

widetildePsi por construcción, por lo que se podrían dar problemas en la estimación.³⁵

A pesar de la utilidad de estos polinomios por parte, todos sufren de problemas más allá del rango de definición $\mathcal{X}_j = [a_j, b_j] \quad \forall j = 1, \dots, d$. Pues, su naturaleza global hace que fuera de la región con nodos los polinomios crezcan o decrezcan rápidamente. Por lo tanto, extrapolar con polinomios es peligroso y podría llevar a predicciones erróneas. Para corregir esto, en ocasiones, se puede imponer una restricción adicional para que el polinomio sea lineal en sus extremos. Se usa el adjetivo de *natural* para designarlos. Esta modificación, libera $2 \times (M - 2)$ funciones bases, pues quita todas las bases de orden mayor a 1 en los dos nodos frontera. Es razonable que esta modificación mejore la fuerza predictiva fuera de el dominio de entrenamiento. Sin embargo, en un contexto de regresión (o clasificación) general, se recomienda no hacer inferencia fuera de el espacio de covariables \mathcal{X}^d , pues en realidad, no se tiene evidencia para tomar conclusiones en esta región.

Al estar trabajando en espacios funcionales, la elección de base es relativamente arbitraria y se podría cambiar como lo hace una transformación de coordenadas en un espacio euclidiano. Cada base tiene sus beneficios y desventajas. Para esta exposición, se escoge la expansión en bases truncadas pues es explicada fácilmente y tiene una forma funcional relativamente sencilla. Además, la interpretación de los coeficientes β es inmediata. Sin embargo, no es buena computacionalmente hablando

35. Bajo el paradigma frecuentista y esta forma funcional, los parámetros también se podrían estimar por un procedimiento de mínimos cuadrados, en donde serían evidentes los problemas en la matriz de correlaciones $\Psi^t \Psi$.

cuando J es grande. En la practica, usualmente se implementan B-Splines³⁶ o bases ortogonales que se derivan de lo estudiados. No obstante, para no complicar más la exposición (y el algoritmo en si) se implementó una versión vectorizada de (21) con base en la Tabla 2 y (22) que se ejecuta bastante rápido inclusive cuando n y J son grandes.

En la practica, los parámetros M , J y K se calibran comparando diferentes alternativas de modelos³⁷ pues, como ya se mencionó anteriormente, hacer J variable y automático es muy complejo.

36. Véase el Capítulo 5.5 de **wasserman2007all** o el Apéndice del Capítulo 5 en **hastie2008elements**.

37. En el Capítulo ?? se discute la selección del modelo.